python: 웹크롤링 Ch. 04



- 1. 셀레니움
- 2. 셀레니움 웹 크롤링

01. 셀레니움

자동화 툴 이해하기

• 자동화 툴은 사람을 대신하여 반복적이고 연속적인 작업을 수행하는 프로그램.

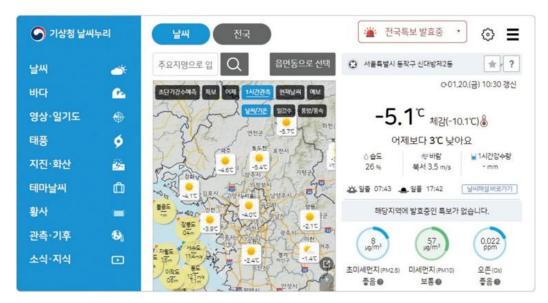


- 셀레니움(Selenium)은 사람을 대신하여 자동으로 웹 브라우저에서 동작을 수행하는 프레임 워크.
- 셀레니움으로 수행할 수 있는 동작은 다양함.

- 동적인 웹페이지와 셀레니움
 - 정적인 페이지(Static web page)는 서버에 저장된 데이터를 그대로 보여주어 시간이 지나도 모습이 변하지 않음.



- 동적인 웹페이지와 셀레니움
 - 동적인 페이지(Dynamic web page)는 사용자가 클릭하거나 텍스트를 입력하여 페이지의 상태를 바꿀 수 있음.



 셀레니움을 이용하면 동적인 페이지의 데이터를 수집하는 데 시간과 노동력을 절감할 수 있음.

- 셀레니움 명령어
 - 웹페이지 접속 : 웹 브라우저 주소창에 www.naver.com을 입력하고 Enter를 입력하는 동작



- 셀레니움에서는 이 동작을 코드 단 한 줄로 표현.

```
driver.get([URL])
```

- get() 함수는 특정 웹페이지에 접속하는 함수.

- 셀레니움 명령어
 - 특정 위치의 텍스트를 찾아서 수집 : '대한민국 정책브리핑' 페이지에 접속하여 주요 뉴스 제목을 수집.



- find_element()는 화면 상의 버튼, 텍스트, 리스트 등 객체를 찾음.

driver.find_element('xpath','[실제 Xpath 값]').text

- 셀레니움 명령어
 - 특정 위치 텍스트 입력: 검색어 입력란에 텍스트를 입력하는 동작.



driver.find_element('xpath','[실제 Xpath 값]').send_keys('[텍스트]')

- 문자열을 입력하는 send_keys() 함수를 호출
- send_keys('코로나')와 같이 명령.

크롤링: 소프트웨어를 통해 인터넷 웹페이지를 돌아다니며 정보를 수집하는 일.

크롤러(Crawler): 이러한 작업을 수행하는 소프트웨어.

셀레니움 설치와 실행

셀레니움을 실행하려면 셀레니움이 조작할 가상의 웹 브라우저를 연동해야 함.

셀레니움 설치와 실행

• 셀레니움을 실행하려면 셀레니움이 조작할 가상의 웹브라우저를 연동해야 함.

```
Code 04-01

01 !pip install selenium

02 import selenium

03 from selenium import webdriver

04 from selenium.webdriver.common.keys import Keys
```

- import 명령어를 사용하여 모듈을 이 코드에서 사용할 수 있도록 가져옴.

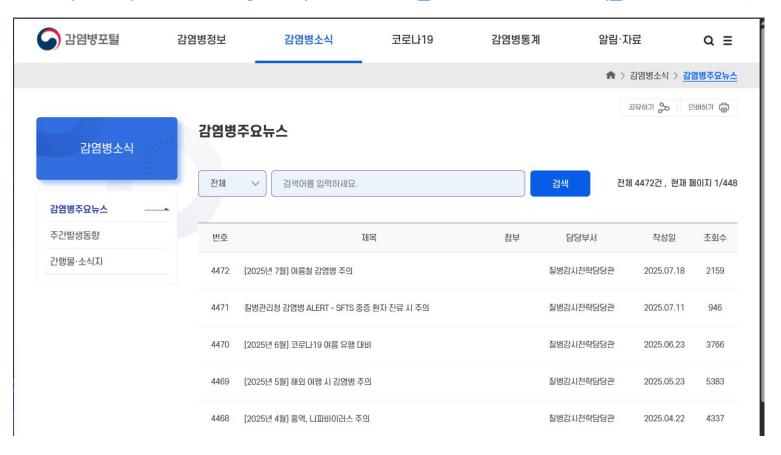
```
Code 04-02

01 options = webdriver.chrome.options.Options()
02 options.add_argument('--headless') # 창이 나타나지 않도록 설정
03 options.add_argument('--no-sandbox')
04 options.add_argument('--disable-dev-shm-usage')
05 driver = webdriver.Chrome(options=options)
```

- 마지막 행에서는 가상의 웹 브라우저에서 창을 열고 이 객체를 변수 driver에 할당.

- 셀레니움으로 웹페이지 접속하기
 - 특정 URL에 접속(감염병 포털 감염병소식

https://dportal.kdca.go.kr/pot/bbs/BD_selectBbsList.do?q_bbsSn=1008)



• 셀레니움으로 웹페이지 접속하기

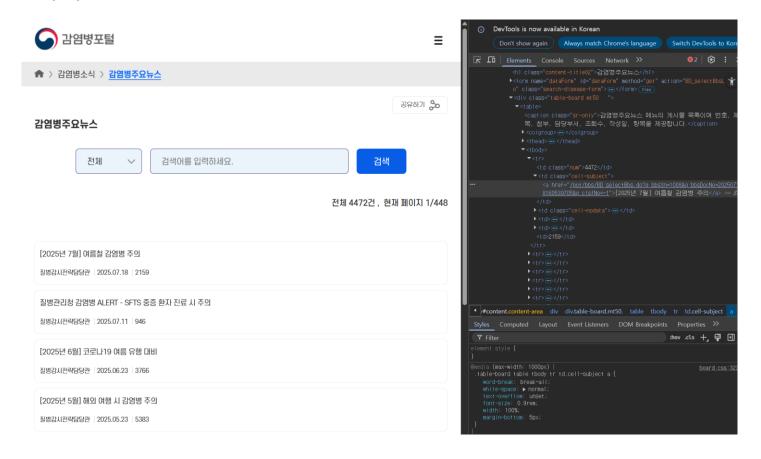
Code 04-03

- 01 url = 'https://dportal.kdca.go.kr/pot/bbs/BD_selectBbsList.do?q_bbsSn=1008'
- 02 driver.get(url)
 - 변수 url에 감염병 포털 페이지의 주소를 문자열로 대입.
 - 변수 url을 driver.get() 함수의 인자로 넣어 해당 웹페이지에 접속

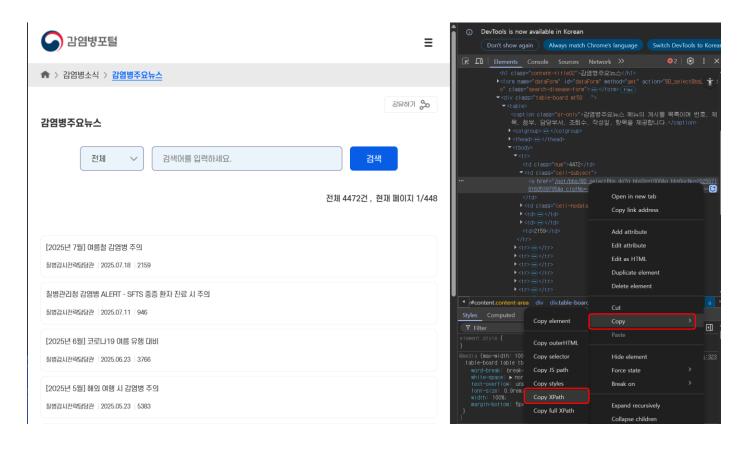
- 최신 뉴스 수집하기
 - 특정 위치의 텍스트를 수집할 때 XPath를 사용.
 - XPath(XML Path Language)란 웹페이지를 설계할 때 사용한 언어 구조로 위치를 특정하는 방식, 알아내는 방법은 마우스 오른쪽 버튼 클릭 후 [검사(Inspect)]선택.



- 최신 뉴스 수집하기
 - 개발자 도구에는 웹페이지를 구성하고 개발할 때 사용한 소스 코드가 나타남.



- 최신 뉴스 수집하기
 - 음영 표시된 코드를 마우스 오른쪽 버튼으로 클릭하고, 메뉴에서 [복사]를 선택하여 XPath를 복사.



- 최신 뉴스 수집하기
 - 메모장에 붙여 넣어서 확인해 보고 XPath는 다음과 같은 모습.

```
//*[@id="content"]/div/div[1]/table/tbody/tr[1]/td[2]/a
```

- 셀레니움에서 복사한 XPath를 그대로 입력하기만 하면 해당 위치에 있는 텍스트를 수집할 수 있음.

topnews=driver.find_element('xpath', '[실제 Xpath 값]')

• 셀레니움으로 웹페이지 접속하기

Code 04-04

- topnews=driver.find_element('xpath','//*[@id="content"]/div/div[1]/ta
 ble/tbody/tr[1]/td[2]/a')
- 02 print(topnews.text)

실행 결과

[2025년 7월] 여름철 감염병 주의

- find_element() 함수가 XPath에 해당하는 객체를 반환하면 객체를 topnews변수에 넣기.
- Topnews 변수에 담은 객체의 텍스트를 가져오기 위해 text 속성을 호출. 그리고 반환되는 값을 print() 함수로 출력하면 뉴스 제목이 출력됨.

- 여러 개의 최신 뉴스를 한꺼번에 수집하기
 - 감염병주요뉴스 1페이지에 있는 제목을 가져오기. 객체의 XPath 값을 각각 복사하고 메모장에 붙여넣기.

```
//*[@id="content"]/div/div[1]/table/tbody/tr[1]/td[2]/a
//*[@id="content"]/div/div[1]/table/tbody/tr[2]/td[2]/a
//*[@id="content"]/div/div[1]/table/tbody/tr[3]/td[2]/a
//*[@id="content"]/div/div[1]/table/tbody/tr[4]/td[2]/a
//*[@id="content"]/div/div[1]/table/tbody/tr[5]/td[2]/a
```

 tr제외한 구문이 모두 일치하는 점을 이용하면 객체 여러 개의 텍스트를 한꺼번에 수집할 수 있음.

• 여러 개의 최신 뉴스를 한꺼번에 수집하기

```
Code 04-05

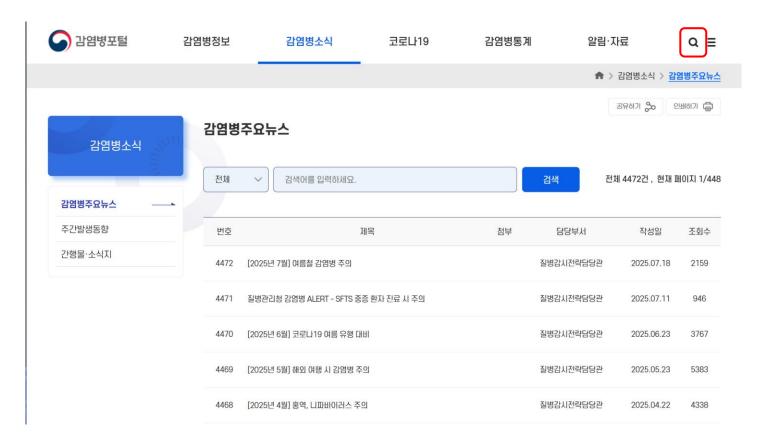
01 topnews =
    driver.find_elements('xpath','//*[@id="content"]/div/div[1]/table/tbo
02 dy')
03

04 #여러 개의 텍스트를 리스트 topnews에 정리하기
05 topnews = [topnew.text for topnew in topnews]
06
    print(topnews)
```

실행 결과

['[2025년 7월] 여름철 감염병 주의 질병감시전략담당관 2025.07.18 2159\n질병관리청 감염병 ALERT - SFTS 중증 환자 진료 시 주의 질병감시전략담당관 2025.07.11 946\n[2025년 6월] 코로나19 여름 유행 대비 질병감시전략담당관 2025.06.23 3766\n[2025년 5월] 해외 여행 시 감염병 주의 질병감시전략담당관 2025.05.23 5383\n[2025년 4월] 홍역, 니파바이러스 주의 질병감시전략담당관 2025.04.22 4337\n[2025년 3월] 새학기 학생 감염병 주의 질병감시전략담당관 2025.03.24 3596\n질병관리청 감염병 ALERT - 에볼라바이러스병 대비/대응 질병감시전략담당관 2025.02.26 2335\n[2025년 2월] 바이러스성 출혈열 유입 주의 질병감시전략담당관 2025.02.21 2734\n[2025년 1월] 설 연휴 호흡기 감염병 주의 질병감시전략담당관 2025.01.24 2199\n[2024년 11월] 최근 증가하는 감염병 주의 질병감시전략담당관 2024.11.25 3629']

- 버튼 클릭하기
 - 감염병주요뉴스 페이지에서 통합 검색을 하려면 먼저 돋보기 버튼을 클릭하여 입력란을 나타내야 함.



- 버튼 클릭하기
 - 셀레니움에서도 돋보기 버튼을 찾아 클릭하는 작업을 자동화 할 수 있음. 개발자 도구에서 돋보기 버튼의 XPath를 복사.

```
//*[@id="gnb"]/div/ul/li[1]/a
```

Code 04-06

- 01 button=driver.find_element('xpath','//*[@id="gnb"]/div/ul/li[1]/a')
- 02 print(button.text)
- 03 button.click()

실행 결과

검색하기

- XPath를 기준으로 찾은 돋보기 버튼 객체를 변수 button에 담기.
- 돋보기 버튼 객체에 click() 함수를 덧붙여 객체를 클릭

- 텍스트 입력하기
 - 감염병포털 페이지에서 돋보기 버튼을 클릭하면 다음 그림처럼 검색어 입력란과 검색 버튼이 나란히 나타남.



- 클릭해야 하는 위치, 즉 검색어 입력란의 XPath를 개발자 모드에서 복사하여 진행.

```
//*[@id="gnb"]/div/ul/li[1]/a
```

• 텍스트 입력하기

```
Code 04-07

01    driver.find_element('xpath','//*[@id="search-searchpage"]').click()
02    driver.find_element('xpath','//*[@id="search-
03    searchpage"]').send_keys('제주도')
04

    driver.find_element('xpath','//*[@id="search-
    searchpage"]').send_keys(Keys.ENTER)
```

- 객체에 무언가를 입력할 때는 send_keys() 함수를 사용.

 Keys.ENTER를 send keys() 함수의 인자로 넣으면 [Enter]를 입력하라는 명령.
- [Code 04-06]와 [Code 04-07]의 검색 작업은 돋보기 버튼을 클릭하고 검색어 입력란을 클릭한 다음 검색어를 입력하고 [Enter]를 입력하는 네 단계로 구분.

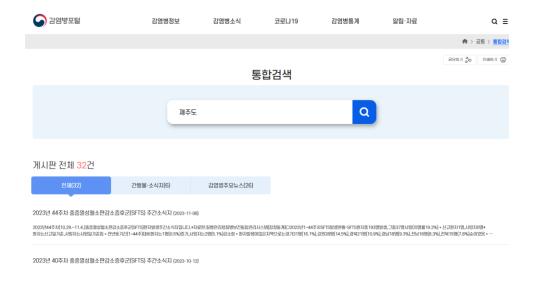
```
driver.find_element('xpath','//*[@id="gnb"]/div/ul/li[1]/a')
driver.find_element('xpath','//*[@id="search-searchpage"]').click()
driver.find_element('xpath','//*[@id="search-searchpage"]').send_keys('제주도')
driver.find_element('xpath','//*[@id="search-
searchpage"]').send_keys(Keys.ENTER)
```

- 텍스트 입력하기
 - 코드에서 반복되는 부분을 변수 serch_for에 담으면 코드를 보다 간결하게 줄일 수 있음

```
driver.find_element('xpath','//*[@id="search-searchpage"]').click()

search_for = driver.find_element('xpath','//*[@id="search-searchpage"]')
search_for.click()
search_for.send_keys('제주도')
search_for.send_keys(Keys.ENTER)
```

- 텍스트 입력하기
 - 여기까지 실행하면 '제주도' 검색 결과 페이지로 이동.



- page_source 속성을 출력하면 소스 코드를 보고 간접적으로 현재 페이지 확인.

Code 04-08
01 print(driver.page_source)

√하나 더 알기: 셀레니움 함수

기능	형식		
뒤로	driver.back()		
앞으로	driver.forward()		
새로고침	driver.refresh()		
탭 닫기	driver.close()		
창 닫기	driver.quit()		
창 최대화	driver.maximize_window()		
창 최소화	driver.minimize_window()		
브라우저 HTML 정보 출력	print(driver.page_source)		

확인 문제

1	다음 중 셀레니움에서	키보드이 틀정	키륵 인력하려	는 한수록 고리시오
ፗ.		, ' I ' - - - 0	, , <u>, , , , , , , , , , , , , , , , , </u>	

1 click()

②keys()

3send_keys()

4 get()

2. 다음을 읽고 빈칸에 들어갈 적절한 단어를 적으시오

셀레니움을 통해 특정 웹페이지에 접속하려면 driver.

을 사용한다.

3. 다음을 읽고 빈칸에 들어갈 적절한 단어를 적으시오.

셀레니움을 통해 특정한 XPath 속성을 가진 객체를 찾으려면

driver.

을 사용한다.

확인 문제

1. 다음 중 셀레니움에서 키보드의 특정 키를 입력하려는 함수를 고르시오. ③

①click()

②keys()

3send_keys()

4 get()

2. 다음을 읽고 빈칸에 들어갈 적절한 단어를 적으시오

셀레니움을 통해 특정 웹페이지에 접속하려면 driver.get([url])을 사용한다.

3. 다음을 읽고 빈칸에 들어갈 적절한 단어를 적으시오.

셀레니움을 통해 특정한 XPath 속성을 가진 객체를 찾으려면 driver.find_element('xpath','[XPath 값])을 사용한다.

감염병포털 데이터 수집

감염병포털 페이지 중 코로나19 페이지에는 코로나19에 대한 정보가 있다. 이 페이지에 있는 코로나19에 대한 정보를 수집하는 웹 크롤러를 작성해 봅시다.



감염병포털 데이터 수집

지금까지 명령어를 활용하여 감염병포털에서 코로나에 대한 데이터를 수집하고, 미리 만들어둔 템플릿에 대입하겠습니다.

```
정의:
원인 병원체:
전파경로:
임상증상:
잠복기 및 전염기간:
```

1. 수집할 웹페이지 URL을 입력하여 접속하는 것으로 시작.

```
Code 04-09

01 url='https://dportal.kdca.go.kr/pot/www/CVID19/CVID19_INFO/DFNTN.jsp'
02 driver.get(url)
```

감염병포털 데이터 수집

2. 객체 5개에 있는 5가지 수를 수집하려면 코드도 5개 필요. 객체의 XPath를 구하여 찾고, 차례로 변수 first_blank, second_blank, third_blank, fourth_blank, fifth_blank에 담기.

```
Code 04-10
    #정의
01
    first blank =
02
    driver.find element('xpath','//*[@id="content"]/div[1]/ul/li').text
03
04
05
    #원인 병원체
    second blank =
06
    driver.find_element('xpath','//*[@id="content"]/div[2]/ul/li').text
07
80
    #전파경로
09
    third blank =
10
    driver.find_element('xpath','//*[@id="content"]/div[3]/ul/li').text
11
12
13
    #임상증상 2가지
14
    fourth blank1 =
15
    driver.find_element('xpath','//*[@id="content"]/div[4]/ul/li[1]').text
     fourth blank2 =
     driver find element('xnath'.'//*[@id="content"]/div[4]/u]/li[2]').text
```

감염병포털 데이터 수집

3. 변수에 담은 텍스트를 출력하여 확인.

Code 04-11

01 print('정의 : ',first_blank,'\n원인 병원체 : ',second_blank,'\n전파경로 : ',third_blank,'\n임상증상 : ',fourth_blank1,',',fourth_blank2,'\n잠복기 및 전염기간 : ',fifth_blank)

실행 결과

정의 : 고로나19바이러스(SARS-CoV-2) 감염에 의한 급성호흡기질환

원인 병원체 : 코로나비리데과(Coronaviridae family)에 속하는 코로나19바이러스(SARS-CoV-2)

전파경로 : 호흡기 비말에 의한 전파

임상증상 : 발열(37.5°C 이상), 기침, 호흡곤란, 오한, 근육통, 두통, 인후통, 후각, 미각소실 등 , 기타 피로, 식욕감소, 가래,

소화기증상(오심, 구토, 설사 등), 혼돈, 어지러움 콧물, 코막힘, 객혈, 흉통, 결막염, 피부증상 등이 동반될 수 있음

잠복기 및 전염기간 : 1~14일(평균 5~7일)

네이버 뉴스 카테고리 가져오기

N 뉴스 | 엔터 | 스포츠 | 날씨 | 프리미엄

언론사별 정치 경제 사회 생활/문화 IT/과학 세계 랭킹 신문보기 오피니언 TV 팩트체크 알고리즘 안내 정정보도 모음

```
options = webdriver.chrome.options.Options()
options.add_argument('--no-sandbox')
options.add_argument('--disable-dev-shm-usage')
driver = webdriver.Chrome(options=options)
url='-----'
driver.get(url)
topnews = driver.find_elements('xpath','-----')
topnews = [-----]
print(topnews)
```

네이버 뉴스 카테고리 가져오기

N 뉴스 | 엔터 | 스포츠 | 날씨 | 프리미엄

언론사별 정치 경제 사회 생활/문화 IT/과학 세계 랭킹 신문보기 오피니언 TV 팩트체크 알고리즘 안내 정정보도 모음

```
options = webdriver.chrome.options.Options()
options.add_argument('--no-sandbox')
options.add_argument('--disable-dev-shm-usage')
driver = webdriver.Chrome(options=options)
url='https://news.naver.com/section/101'
driver.get(url)
topnews = driver.find_elements('xpath','//*[@id="_LNB"]/ul')
topnews = [topnew.text for topnew in topnews]
print(topnews)
```

네이버 경제 뉴스 수집



topnews=driver.find_element('xpath','----').click()

네이버 경제 뉴스 수집



topnews=driver.find_element('xpath','//*[@id="ct_wrap"]/div[2]/div[1]/div/ul/li[8]/
a').click()

네이버 경제 뉴스 수집

경제 일반

최신순
 날짜별



제주삼다수, '제15회 제주물 세계포럼' 개최

제주삼다수 운영사인 제주개발공사가 30일, 10월 1일 해비치 호텔앤드리조트 제주에서 ' \cdot 스포츠동아 · 1분전



미래에셋, 전세계 운용자산 450조원 돌파…"혁신·신뢰로 성장"

총 운용자산 45%가 해외 운용…글로벌 ETF도 250조원 넘어 미래에셋자산운용이 전 세… 연합뉴스 ' 2분전



'항공일자리 창출' 티웨이항공, 국토교통부 장관 표창 수상

티웨이항공이 '2025 제8회 항공산업 JOB FAIR'에서 항공 일자리 창출에 기여한 점을 인… 스포츠조선 - 2부전



동서식품, 2025 카누 바리스타 챔피언십 성료

동서식품이 '2025 카누 바리스타 챔피언십'을 성황리에 마무리했다고 29일 밝혔다. 동서… 서울경제 ' 2분전



[하우머니] 이번주에 소개할 산업 리포트와 탐방 보고서는?

■ 머니쇼 '하우머니' - 한용희 그로쓰리서치 수석연구원 오늘(29일)의 국내증시 개장 후 · · · SBS Biz · 3분전



'네이버 편입' 두나무 주주는 누구?…한화투자증권 14%↑ [특징주]

네이버가 두나무를 자회사로 편입할 것으로 알려진 가운데 두나무 주요 주주에 대한 관심… 데일리안 3분전

네이버 경제 뉴스 수집

경제 일반

최신순
 날짜별



제주삼다수, '제15회 제주물 세계포럼' 개최

제주삼다수 운영사인 제주개발공사가 30일, 10월 1일 해비치 호텔앤드리조트 제주에서 ' \cdots 스포츠동아' 1분전



미래에셋, 전세계 운용자산 450조원 돌파…"혁신·신뢰로 성장"

총 운용자산 45%가 해외 운용…글로벌 ETF도 250조원 넘어 미래에셋자산운용이 전 세… 연합뉴스 · 2분전



'항공일자리 창출' 티웨이항공, 국토교통부 장관 표창 수상

티웨이항공이 '2025 제8회 항공산업 JOB FAIR'에서 항공 일자리 창출에 기여한 점을 인… 스포츠조선 - 2분전



동서식품, 2025 카누 바리스타 챔피언십 성료

동서식품이 '2025 카누 바리스타 챔피언십'을 성황리에 마무리했다고 29일 밝혔다. 동서… 서울경제 ' 2분전



[하우머니] 이번주에 소개할 산업 리포트와 탐방 보고서는?

■ 머니쇼 '하우머니' - 한용희 그로쓰리서치 수석연구원 오늘(29일)의 국내증시 개장 후 · · · SBS Biz · 3분전



'네이버 편입' 두나무 주주는 누구?…한화투자증권 14%↑ [특징주]

네이버가 두나무를 자회사로 편입할 것으로 알려진 가운데 두나무 주요 주주에 대한 관심… 데일리안 3분전 topnews =
driver.find_elements('xpath','//*[@id="new
sct"]/div[2]/div/div[1]/div[1]/ul')

topnews = [topnew.text for topnew in topnews]

print(topnews)

네이버 생활/문화 뉴스 수집



topnews=driver.find_element('xpath','-----').click()

네이버 생활/문화 뉴스 수집



topnews=driver.find_element('xpath','//*[@id="_LNB"]/ul/li[5]/a').click()
topnews=driver.find_element('xpath','//*[@id="ct_wrap"]/div[2]/div[1]/div/ul/li[5]/a').click()

네이버 생활/문화 뉴스 수집

음식/맛집 • 최신순 • 날짜별 ∨



식지 않는 말차 열풍…3주만에 100만개 팔려나간 편의점 빵

올여름 MZ(밀레니얼+Z)세대를 중심으로 유행한 말차 열풍이 꾸준히 열기를 이어가고 있한 한국경제: 15분전



"금요일은 공항으로 퇴근" 하나투어, 상해 밤도깨비 여행 출시

하나투어가 2030 직장인과 주말 여행객들이 부담 없이 해외여행을 즐길 수 있도록 '상해 ··· 아시아경제 ' 31분전



[K-VIBE] 신종근의 'K-리큐르' 이야기…우리나라에 선인장 술이 있다?

편집자 주 = 한국국제교류재단(KF)의 지난해 발표에 따르면 세계 한류 팬은 약 2억2천50··· 연한뉴스 · 34분전



동서식품, '2025 카누 챔피언십' 개최…김가은 바리스타 우승

동서식품은 27~28일 서울 신세계백화점 강남점 센트럴시티 오픈스테이지에서 '2025 카·· 아시아경제 · 38분전



명륜당 가맹점주 480명 "상생협력 모범" 본사 지지

무한리필 돼지갈비 프랜차이즈 '명륜진사갈비'를 운영하는 명륜당이 대부업 논란이 불거·· 아시아경제 · 52분전



이연복, 2년 만에 집 장만한 '대박 메뉴 공개'

이연복. 사진 | MBC '중식 대가' 이연복이 메뉴 하나로 대박 난 일화를 공개한다. 29일 방… 스포츠서울 1시간전

네이버 생활/문화 뉴스 수집

음식/맛집 • 최신순 • 날짜별 ∨



식지 않는 말차 열풍…3주만에 100만개 팔려나간 편의점 빵

올여름 MZ(밀레니얼+Z)세대를 중심으로 유행한 말차 열풍이 꾸준히 열기를 이어가고 있… 한국경제 · 15분전



"금요일은 공항으로 퇴근" 하나투어, 상해 밤도깨비 여행 출시

하나투어가 2030 직장인과 주말 여행객들이 부담 없이 해외여행을 즐길 수 있도록 '상해 ·· 아시아경제 : 31분전



[K-VIBE] 신종근의 'K-리큐르' 이야기…우리나라에 선인장 술이 있다?

편집자 주 = 한국국제교류재단(KF)의 지난해 발표에 따르면 세계 한류 팬은 약 2억2천50·· 연합뉴스 · 34분전



동서식품, '2025 카누 챔피언십' 개최…김가은 바리스타 우승

동서식품은 27~28일 서울 신세계백화점 강남점 센트럴시티 오픈스테이지에서 '2025 카… 아시아경제: 38분전



명륜당 가맹점주 480명 "상생협력 모범" 본사 지지

무한리필 돼지갈비 프랜차이즈 '명륜진사갈비'를 운영하는 명륜당이 대부업 논란이 불거·· 아시아경제 · 52분전



이연복, 2년 만에 집 장만한 '대박 메뉴 공개'

이연복. 사진 | MBC '중식 대가' 이연복이 메뉴 하나로 대박 난 일화를 공개한다. 29일 방… 스포츠서울 1시간전

```
topnews =
driver.find_elements('xpath','//*[@id="new
sct"]/div[2]/div/div[1]/div[1]')
```

topnews = [topnew.text for topnew in topnews]

print(topnews)